

# **Derin Öğrenme Yöntemlerini Kullanarak**

## **Kedileri ve Köpekleri Ayırt Etmek**

### **Using Deep Learning Methods**

### **Distinguishing Cats and Dogs**

**Burak Büyükdağdaş**

Öğrenci

İzmir Katip Çelebi Üniversitesi

İzmir/Türkiye

iz.burak@hotmail.com

**Özet** — Derin öğrenme yöntemleri kullanarak, kedileri ve köpekleri ayırt etmek amacıyla bir projeyi tamamladık. Projemizde, farklı derin öğrenme mimarilerini kullanarak veri kümesini değerlendirdik. Kullanılan mimariler şunlardır: VGG, ResNet, Inception ağları, MobileNet, DenseNet. VGG, geniş ve derin ağ mimarisi ile tanınırken, ResNet, ağın derinliğini artıran bağlantılarıyla dikkat çekmektedir. Inception ağları, paralel olarak çalışan farklı boyutlardaki filtrelerin birleştirilmesiyle karmaşık yapıları çözmek için tasarlanmıştır. MobileNet, hafif ve hızlı bir mimariye sahiptir ve mobil cihazlarda uygulama için idealdir. DenseNet ise yoğun bağlantıları kullanarak bilgi akışını iyileştirir ve ağın daha etkili öğrenme yapmasını sağlar. Bu çalışma, kedileri ve köpekleri ayırt etme probleminde farklı derin öğrenme mimarilerinin performansını karşılaştırmayı amaçlamaktadır. Değerlendirme, doğruluk (accuracy), hassasiyet (precision), duyarlılık (recall), F1 skoru ve ROC AUC skoru gibi ölçütlere dayanmaktadır. Her bir mimari için bu ölçütler hesaplanmış ve sonuçlar karşılaştırılmıştır. Sonuçlar, farklı mimarilerin performansının değişebileceğini göstermektedir.

**Anahtar Kelimeler** — VGG, ResNet, Inception ağları, MobileNet, DenseNet

**Abstract** — We have completed a project aiming to distinguish between cats and dogs using deep learning methods. In our project, we evaluated the dataset using various deep learning architectures. The architectures used are as follows: VGG, ResNet, Inception networks, MobileNet, and DenseNet. VGG is known for its wide and deep network architecture, while ResNet stands out with its connections that increase the depth of the network. Inception networks are designed to solve complex structures by combining filters of different sizes that work in parallel. MobileNet has a lightweight and fast architecture, making it ideal for applications on mobile devices. DenseNet improves information flow by using dense connections, enabling the network to learn more effectively. This study aims to compare the performance of different deep learning architectures in the

task of distinguishing between cats and dogs. The evaluation is based on metrics such as accuracy, precision, recall, F1 score, and ROC AUC score. These metrics were calculated for each architecture, and the results were compared. The results demonstrate that the performance of different architectures can vary.

*Keywords — VGG, ResNet, Inception ağırları, MobileNet, DenseNet*

## *Giriş*

Bu çalışma, kedileri ve köpekleri ayırt etmek amacıyla derin öğrenme yöntemlerinin kullanıldığı bir projeyi ele almaktadır. Veri kümesi üzerinde en az 5 farklı derin öğrenme mimarisini karşılaştırarak, hangi mimarinin en iyi performansı sergilediğini belirlemeyi hedeflemektedir. Proje kapsamında VGG, ResNet, Inception ağırları, MobileNet ve DenseNet gibi tanınmış ve yaygın kullanılan derin öğrenme mimarileri incelenmiştir. Her bir mimari, farklı özelliklere sahip olduğundan, performansları da değişebilmektedir. Örneğin, VGG geniş ve derin ağ yapısıyla tanınırken, ResNet ağı derinliğini artıran bağlantılar kullanmaktadır. Inception ağı ise paralel olarak çalışan filtrelerin birleştirilmesiyle karmaşık yapıları ele alırken, MobileNet hafif ve hızlı bir mimariye sahiptir. DenseNet ise yoğun bağlantılar kullanarak daha etkili öğrenme sağlar. Bu çalışmanın amacı, kedileri ve köpekleri ayırt etme problemini çözmek için en uygun derin öğrenme mimarisini belirlemektir. Bu amaç doğrultusunda, veri kümesi üzerinde eğitim ve değerlendirme adımları gerçekleştirilmiştir. Performans ölçütleri arasında doğruluk (accuracy), hassasiyet (precision), duyarlılık (recall), F1 skoru ve ROC AUC skoru yer almaktadır. Sonuçlar, farklı derin öğrenme mimarilerinin performansının değişebildiğini göstermektedir. Bu çalışma, kedileri ve köpekleri ayırt etmek için en etkili derin öğrenme yöntemini belirleyerek, ilgili alanda yapılan çalışmalara katkı sağlamayı amaçlamaktadır.

## *Yöntemler*

Bu çalışma, kedileri ve köpekleri ayırt etmek için derin öğrenme yöntemlerinin kullanıldığı bir projeyi ele almaktadır. Veri seti olarak "Kaggle Cats and Dogs Dataset" kullanılmıştır, bu veri seti içerisinde kedilere ve köpekler için görseller bulunmaktadır. İlk aşamada, veri setindeki kedi ve köpek resimlerini 1000'er adede indirilmiştir. Çalışmanın başlangıcında, kullanılacak derin öğrenme mimarilerini belirlemek için dikkatle seçim yapılmıştır. İncelenen mimariler arasında VGG, ResNet, Inception ağırları, MobileNet ve DenseNet yer almaktadır. Her bir mimarinin farklı özelliklere sahip olduğu ve performansının değişebileceği bilinmektedir. Veri toplama süreci, Kaggle Cats and Dogs Dataset'i kullanarak gerçekleştirilmiştir. Bu veri seti, internetten derlenen ve çeşitli kaynaklardan toplanan kedi ve köpek görsellerini içermektedir. Veri seti, doğruluk ve çeşitlilik açısından dikkatlice seçilmiş ve incelenmiştir. İlk aşamada, veri setindeki görseller sayısal formata dönüştürülmüş ve ardından kedi ve köpek resimlerinin sayısı 1000'er adede düşürülmüştür. Bu adım, daha odaklı ve yönetilebilir bir veri kümesi elde etmek amacıyla gerçekleştirilmiştir. Çalışmanın devamında, seçilen derin öğrenme mimarileri kullanılarak eğitim ve değerlendirme adımları gerçekleştirilmiştir. Her bir mimari, önceden eğitilmiş ağı temel alarak model oluşturma ve ayarlamayı içeren bir süreçle uygulanmıştır. Eğitim adımında, veri kümesi üzerindeki kedi ve köpek görselleri kullanılarak modeller eğitilmiştir. Eğitim süreci, modelin görsel özellikleri ve desenleri öğrenmesini sağlamak amacıyla iteratif olarak gerçekleştirilmiştir. Değerlendirme aşamasında, eğitilen modeller kullanılarak test veri kümesi üzerinde performans ölçütleri hesaplanmıştır. Doğruluk (accuracy), hassasiyet (precision), duyarlılık (recall), F1 skoru ve ROC AUC skoru gibi metrikler kullanılarak her bir modelin performansı değerlendirilmiştir. Bu adım, farklı derin öğrenme mimarilerinin kedileri ve köpekleri ayırt etme konusundaki etkinliğini karşılaştırmak ve en iyi sonuçları elde etmek amacıyla gerçekleştirilmiştir.

## *Bulgular*

Projede kullanılan VGG modelinin performansını değerlendirmek için çeşitli metriklerin kullanıldığını göstermektedir. İşte bu metriklerin anlamları ve VGG modelinin elde ettiği sonuçlar:

Accuracy :	0.9939909864797169
Precision :	0.9920398009950249
Recall :	0.996003996003996
F1 Score :	0.9940179461615156
ROC AUC Score :	0.9939859337449699

Accuracy (Doğruluk): Doğru tahminlerin toplam verilere oranını gösterir. VGG modeli, %99.40 doğruluk skoruyla yüksek bir başarı elde etmiştir.

Precision (Kesinlik): Pozitif olarak tahmin edilen örneklerin gerçekten pozitif olduğu oranı gösterir. VGG modeli, %99.20 kesinlik skoruyla yanlış pozitiflerin sayısını düşük tutmuştur.

Recall (Duyarlılık): Gerçek pozitiflerin tespit edilme oranını gösterir. VGG modeli, %99.60 duyarlılık skoruyla gerçek pozitiflerin çoğunu yakalamıştır.

F1 Score: Precision ve recall metriklerinin harmonik ortalamasını gösterir. VGG modeli, %99.40 F1 skoruyla hem yanlış pozitifleri hem de yanlış negatifleri minimize etmiştir.

ROC AUC Score: Receiver Operating Characteristic (ROC) eğrisi altındaki alanı gösterir. VGG modeli, %99.40 ROC AUC skoru elde ederek sınıflandırma performansını değerlendirmiştir.

Projede kullanılan ResNet modelinin performansını değerlendirmek için çeşitli metriklerin kullanıldığını göstermektedir. İşte bu metriklerin anlamları ve ResNet modelinin elde ettiği sonuçlar:

Accuracy :	0.9914872308462694
Precision :	0.989065606361829
Recall :	0.994005994005994
F1 Score :	0.9915296462381665
ROC AUC Score :	0.9914809086495833

Accuracy (Doğruluk): Doğru tahminlerin toplam verilere oranını gösterir. ResNet modeli, %99.15 doğruluk skoruyla yüksek bir başarı elde etmiştir.

Precision (Kesinlik): Pozitif olarak tahmin edilen örneklerin gerçekten pozitif olduğu oranı gösterir. ResNet modeli, %98.91 kesinlik skoruyla yanlış pozitiflerin sayısını düşük tutmuştur.

Recall (Duyarlılık): Gerçek pozitiflerin tespit edilme oranını gösterir. ResNet modeli, %99.40 duyarlılık skoruyla gerçek pozitiflerin çoğunu yakalamıştır.

F1 Score: Precision ve recall metriklerinin harmonik ortalamasını gösterir. ResNet modeli, %99.15 F1 skoruyla hem yanlış pozitifleri hem de yanlış negatifleri minimize etmiştir.

ROC AUC Score: Receiver Operating Characteristic (ROC) eğrisi altındaki alanı gösterir. ResNet modeli, %99.15 ROC AUC skoru

elde ederek sınıflandırma performansını değerlendirmiştir.

Projede kullanılan InceptionV3 modelinin performansı değerlendirilmiştir. İşte elde edilen sonuçlar ve bu sonuçlarla ilgili açıklamalar:

Accuracy :	0.9248873309964948
Precision :	0.9455497382198953
Recall :	0.9020979020979021
F1 Score :	0.9233128834355828
ROC AUC Score :	0.9249445333782683

Accuracy (Doğruluk): Modelin doğru sınıflandırma oranını yansıtan bu metrik, %92.49 doğruluk skoruyla iyi bir performans sergilediğini gösterir. Modelin verileri doğru bir şekilde sınıflandırmada başarılı olduğunu gösterir.

Precision (Kesinlik): Pozitif olarak tahmin edilen örneklerin gerçek pozitiflerle uyumunu gösteren bu metrik, %94.55 kesinlik skoruyla yüksek bir değer elde edilmiştir. Modelin yanlış pozitif sınıflandırmaları minimumda tuttuğunu gösterir.

Recall (Duyarlılık): Gerçek pozitiflerin tespit edilme oranını gösteren bu metrik, %90.21 duyarlılık skoruyla başarılı bir sonuç elde edilmiştir. Modelin gerçek pozitifleri büyük ölçüde doğru bir şekilde tespit ettiğini gösterir.

F1 Score: Precision ve recall metriklerinin harmonik ortalamasını gösteren F1 Skoru, %92.33 değeriyle modelin hem precision hem de recall değerlerine dengeli bir şekilde odaklandığını gösterir.

ROC AUC Score: Receiver Operating Characteristic (ROC) eğrisi altında kalan alanı temsil eden bu metrik, %92.49 değeriyle modelin sınıflandırma performansının iyi olduğunu gösterir. Modelin sınıflandırmada etkili bir şekilde ayrım yaptığını gösterir.

Projede MobileNet modeli kullanılarak elde edilen sonuçlar incelenmiştir. Aşağıda bulunan sonuçlar ve bunlarla ilgili açıklamalar yer almaktadır:

Accuracy :	0.9594391587381071
Precision :	0.9545454545454546
Recall :	0.965034965034965
F1 Score :	0.9597615499254843
ROC AUC Score :	0.9594251130395709

Accuracy (Doğruluk): Modelin doğru sınıflandırma oranını gösteren bu metrik, %95.94 doğruluk skoruyla yüksek bir başarı elde ettiğini göstermektedir. Modelin genel olarak doğru tahminlerde bulunduğunu ifade etmektedir.

Precision (Kesinlik): Pozitif olarak sınıflandırılan örneklerin gerçek pozitiflerle uyumunu gösteren bu metrik, %95.45 kesinlik skoruyla başarılı bir sonuç ortaya koymuştur. Modelin yanlış pozitif sınıflandırmaları minimumda tuttuğunu göstermektedir.

Recall (Duyarlılık): Gerçek pozitiflerin tespit edilme oranını ifade eden bu metrik, %96.50 duyarlılık skoruyla yüksek bir değer elde etmiştir. Modelin gerçek pozitifleri büyük oranda doğru bir şekilde tespit ettiğini göstermektedir.

F1 Score: Precision ve recall metriklerinin harmonik ortalamasını ifade eden F1 Skoru, %95.98 değeriyle modelin hem kesinlik hem de duyarlılık değerlerine dengeli bir şekilde odaklandığını göstermektedir.

ROC AUC Score: Receiver Operating Characteristic (ROC) eğrisi altında kalan alanı temsil eden bu metrik, %95.94 değeriyle modelin sınıflandırma performansının iyi olduğunu göstermektedir. Modelin sınıflandırmada etkili bir şekilde ayrım yaptığını ifade etmektedir.

Projede DenseNet modeli kullanılarak elde edilen sonuçlar incelenmiştir. Aşağıda bulunan sonuçlar ve bunlarla ilgili açıklamalar yer almaktadır:

Accuracy :	0.5012518778167251
Precision :	0.5012518778167251
Recall :	1.0
F1 Score :	0.6677785190126752
ROC AUC Score :	0.5

Accuracy (Doğruluk): Modelin doğru sınıflandırma oranını gösteren bu metrik, %50.13 düşük bir doğruluk skoru elde etmiştir. Bu, modelin tahminlerinin rastgele tahmin seviyesinde olduğunu ve verileri doğru bir şekilde sınıflandıramadığını göstermektedir.

Precision (Kesinlik): Pozitif olarak sınıflandırılan örneklerin gerçek pozitiflerle uyumunu gösteren bu metrik, %50.13 değeriyle modelin gerçek pozitifleri doğru bir şekilde sınıflandırma yeteneğinin düşük olduğunu ifade etmektedir.

Recall (Duyarlılık): Gerçek pozitiflerin tespit edilme oranını ifade eden bu metrik, %100.00 değeriyle modelin gerçek pozitif örneklerin tamamını doğru bir şekilde tanımlama eğiliminde olduğunu göstermektedir. Ancak, bu yüksek recall değeri diğer değerlendirme ölçütlerine yansımamıştır.

F1 Score: Precision ve recall metriklerinin harmonik ortalamasını ifade eden F1 Skoru, %66.78 değeriyle modelin precision ve recall değerleri arasında bir denge sağlamadığını göstermektedir. Bu düşük değer, modelin sınıflandırma performansının zayıf olduğunu göstermektedir.

ROC AUC Score: Receiver Operating Characteristic (ROC) eğrisi altında kalan alanı temsil eden bu metrik, %50.00 değeriyle modelin sınıflandırma performansının rastgele seviyede olduğunu göstermektedir.

Sonuçlara bakıldığında, DenseNet modelinin kedi ve köpek görüntülerini başarılı bir şekilde sınıflandıramadığı ve düşük bir performans sergilediği görülmektedir.

## Tartışma

Tabloda verilen sonuçlara dayanarak yapılan analizlere göre, VGG ve ResNet gibi derin sinir ağı modellerinin kedi ve köpek sınıflandırma görevinde daha yüksek performans sergilediği gözlenmiştir. Bu sonuçlar, literatürde de genellikle kabul gören bir bulgudur. VGG ve ResNet gibi modeller, daha fazla katman ve parametreye sahip olmaları nedeniyle karmaşık özellikleri öğrenebilme yetenekleriyle tanınır. Bu durum, kedi ve köpek gibi görsel veriler üzerinde daha iyi sonuçlar elde etmelerini sağlar.

Diğer taraftan, Inception ve MobileNet gibi modellerin performansı da kabul edilebilir düzeydedir, ancak VGG ve

ResNet'e göre biraz daha düşüktür. Bu modeller, daha hafif ve hesaplama açısından daha verimli yapıları nedeniyle tercih edilebilirler, özellikle sınırlı kaynaklara sahip cihazlarda kullanım için uygundurlar.

DenseNet modelinin performansının düşük olduğu görülmektedir. Bu sonuç, literatürde nadir görülen bir durumdur. DenseNet, yoğun bağlantılar kullanarak önceki katmanların çıktılarını bir sonraki katmana ileten bir yapıya sahiptir. Bu nedenle, daha fazla bilgi akışı sağlayarak öğrenme sürecini geliştirmesi beklenir. Ancak, bu durumda modelin performansının düşük olması, modelin belki de daha derin veya daha karmaşık bir yapıya ihtiyaç duyabileceğini düşündürülebilir.

İleriye dönük öneriler olarak, daha fazla veri toplama veya mevcut veriyi artırma, eğitim süresini ve hiperparametreleri ayarlama, daha ileri sinir ağı modellerini veya model kombinasyonlarını deneme önerilmektedir. Bu önerilerle modelin geliştirilmesi ve kedi-köpek sınıflandırma görevinde daha yüksek performans elde edilmesi hedeflenmektedir.

## Sonuç

Sonuçlara bakıldığında, VGG ve ResNet modellerinin en yüksek doğruluk, kesinlik, recall, F1 skoru ve ROC AUC skorlarına sahip olduğunu görüyoruz. Bu iki model, kedi ve köpek görüntülerini başarılı bir şekilde sınıflandırmada en iyi performansı göstermektedir. MobileNet modeli de diğer modellere kıyasla yüksek performans sergilemektedir, ancak VGG ve ResNet'ten biraz daha düşük sonuçlar elde etmektedir.

Öte yandan, Inception modelinin performansı diğer modellere göre daha düşük olduğu ve DenseNet modelinin ise düşük performans gösterdiği görülmektedir. Inception ve DenseNet modelleri, kedi ve köpek sınıflandırmasında geliştirilmeye ihtiyaç duyan modeller olarak değerlendirilebilir.

Sonuç olarak, VGG ve ResNet gibi derin sinir ağı modelleri, kedi ve köpekleri ayırt etme görevinde daha iyi performans göstermektedir. Bu modeller, yüksek doğruluk, kesinlik, recall, F1 skoru ve ROC AUC skorlarıyla dikkat çekmektedir. Diğer modeller ise daha düşük performansa sahip olup, iyileştirme çalışmaları gerektirebilir.

## Kaynaklar

Veri Seti: Kaggle Cats and Dogs Dataset

Öztürk, F. (2020). Derin Öğrenme: Nesne Tanıma ve Sınıflandırma. Seçkin Yayıncılık.

Aytekin, Ö., & Karakaya, M. (2018). Derin Öğrenme ile Yapay Zeka Uygulamaları. Seçkin Yayıncılık.

Baş, M., & Ekşioğlu, B. (2018). Derin Öğrenme: TensorFlow ile Python Ve Keras Kütüphaneleri. Ankara Üniversitesi Basımevi.

Chollet, F. (2017). Deep learning with Python. Manning Publications.

Goodfellow, I., Bengio, Y., & Courville, A. (2016). Deep learning. MIT press.

Acar, E., & Yıldırım, S. (2018). Derin Öğrenme ve Uygulamaları. Birleşik Yayınevi.

